

Machine Learning Assignment 6 (SVM)

Due: 2, June

1. [35pts] Support Vector Machine

(1) Recall that the soft margin support vector machine solves the problem:

$$\begin{aligned} \min \quad & \frac{1}{2} w^\top w + C \sum_i \varepsilon_i \\ \text{s.t.} \quad & y_i(w^\top x_i + b) \geq 1 - \varepsilon_i, \quad \varepsilon_i \geq 0. \end{aligned}$$

- a) [10pts] Derive its dual problem using the method of Lagrange multipliers.
b) [10pts] Further simplify the dual problem when at its saddle point to prove


$$\begin{aligned} \max_{\alpha} \quad & \sum_i \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j x_i^\top x_j \\ \text{s.t.} \quad & C \geq \alpha_i \geq 0, \quad \sum_i \alpha_i y_i = 0, \end{aligned}$$

is equivalent to the primal problem.

(2) [15pts] Given the XOR sample points as below, we train an SVM with a quadratic kernel,

i.e. our kernel function is a polynomial kernel of degree 2: $\kappa(x_i, x_j) = (x_i^\top x_j)^d, d = 2$.

(a) [5pts] what is the corresponding mapping function $\phi(x)$?



(b) [5pts] Use the following code to generate XOR data, and according to the answer of (a), map the data with $\phi(x)$ to see if it can be linearly separable.

(c) [5pts] Could we get a reasonable model with hard margin? If yes, draw the decision boundary in the figure (original feature space), otherwise state reasons.

```

import numpy as np
import matplotlib.pyplot as plt
#创建数据
X_xor = np.random.randn(40,2)
y_xor = np.logical_xor(X_xor[:,0]>0, X_xor[:,1]>0)
y_xor = np.where(y_xor, 1, -1)
#绘制散点图
plt.scatter(x=X_xor[y_xor==1,0]), # 横坐标
            y=X_xor[y_xor==1,1]), # 纵坐标
            color='g', marker='x', label='1')
plt.scatter(x=X_xor[y_xor==-1,0]),
            y=X_xor[y_xor==-1,1]),
            color='b', marker='o', label='-1')
plt.legend() #显示图例
plt.show()

```

2. [30pts] Kernel Functions

- (1) [15 pts] 对于 $\mathbf{x}, \mathbf{y} \in \mathbb{R}^N$, 考虑函数 $\kappa(\mathbf{x}, \mathbf{y}) = \tanh(a\mathbf{x}^\top \mathbf{y} + b)$, 其中 a, b 是任意实数。试说明 $a \geq 0, b \geq 0$ 是 κ 为核函数的必要条件。
- (2) [15 pts] 考虑 \mathbb{R}^N 上的函数 $\kappa(\mathbf{x}, \mathbf{y}) = (\mathbf{x}^\top \mathbf{y} + c)^d$, 其中 c 是任意实数, d, N 是任意正整数。试分析函数 κ 何时是核函数, 何时不是核函数, 并说明理由。

说明: 该核函数是多项式核的更一般的形式。

(第(3)小题是 extra 部分, 可选)

- (3) [10 pts] 当上一小问中的函数是核函数时, 考虑 $d = 2$ 的情况, 此时 κ 将 N 维数据映射到了什么空间中? 具体的映射函数是什么? 更一般的, 对 d 不加限制时, κ 将 N 维数据映射到了什么空间中? (本小问的最后一问可以只写结果)

(可中文作答)

3. [35 pts] Kernel Methods

请给出 kernel PCA 的推导过程。

(可中文作答)

4. [extra, 30pts] Surrogate Function in SVM & Bayesian Optimal Classifier

(本题可选)

在软间隔支持向量机问题中，我们的优化目标为

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m \ell_{0/1}(y_i(\mathbf{w}^T \mathbf{x}_i + b) - 1). \quad (1)$$

然而 $\ell_{0/1}$ 数学性质不太好，它非凸、非连续，使得式 (1) 难以求解。实践中我们通常会将其替换为“替代损失”，替代损失一般是连续的凸函数，且为 $\ell_{0/1}$ 的上界，比如 hinge 损失，指数损失，对率损失。下面我们证明在一定的条件下，这样的替换可以保证最优解不变。

我们考虑实值函数 $h: \mathcal{X} \rightarrow \mathbb{R}$ 构成的假设空间，其对应的二分类器 $f_h: \mathcal{X} \rightarrow \{+1, -1\}$ 为

$$f_h(x) = \begin{cases} +1 & \text{if } h(x) \geq 0 \\ -1 & \text{if } h(x) < 0 \end{cases}$$

h 的期望损失为 $R(h) = \mathbb{E}_{(x,y) \sim \mathcal{D}} [I_{f_h(x) \neq y}]$ ，其中 I 为指示函数。设 $\eta(x) = \mathbb{P}(y = +1|x)$ ，则贝叶斯最优分类器当 $\eta(x) \geq \frac{1}{2}$ 时输出 1，否则输出 -1。因此可以定义贝叶斯得分 $h^*(x) = \eta(x) - \frac{1}{2}$ 和贝叶斯误差 $R^* = R(h^*)$ 。

设 $\Phi: \mathbb{R} \rightarrow \mathbb{R}$ 为非减的凸函数且满足 $\forall u \in \mathbb{R}, 1_{u \leq 0} \leq \Phi(-u)$ 。对于样本 (x, y) ，定义函数 h 在该样本的 Φ -损失为 $\Phi(-yh(x))$ ，则 h 的期望损失为 $\mathcal{L}_\Phi(h) = \mathbb{E}_{(x,y) \sim \mathcal{D}} [\Phi(-yh(x))]$ 。定义 $L_\Phi(x, u) = \eta(x)\Phi(-u) + (1 - \eta(x))\Phi(u)$ ，设 $h_\Phi^*(x) = \operatorname{argmin}_{u \in [-\infty, +\infty]} L_\Phi(x, u)$ ， $\mathcal{L}_\Phi^* = \mathcal{L}_\Phi(h_\Phi^*)$ 。

我们考虑如下定理的证明：

若对于 Φ ，存在 $s \geq 1$ 和 $c > 0$ 满足对 $\forall x \in \mathcal{X}$ 有

$$|h^*(x)|^s = \left| \eta(x) - \frac{1}{2} \right|^s \leq c^s [L_\Phi(x, 0) - L_\Phi(x, h_\Phi^*(x))] \quad (2)$$

则对于任何假设 h ，有如下不等式成立

$$R(h) - R^* \leq 2c [\mathcal{L}_\Phi(h) - \mathcal{L}_\Phi^*]^{\frac{1}{s}} \quad (3)$$

(1) [5 pts] 请证明

$$\Phi(-2h^*(x)h(x)) \leq L_\Phi(x, h(x)) \quad (4)$$

(2) [10 pts] 请证明

$$R(h) - R^* = 2 \mathbb{E}_{x \sim \mathcal{D}_x} [|h^*(x)| 1_{h(x)h^*(x) \leq 0}] \quad (5)$$

提示：先证明

$$R(h) = \mathbb{E}_{x \sim \mathcal{D}_x} [2h^*(x)1_{h(x) < 0} + (1 - \eta(x))]$$

(3) [10 pts] 利用式 (4) 和式 (5) 完成定理的证明。

(4) [5 pts] 请验证对于 Hinge 损失 $\Phi(u) = \max(0, 1 + u)$ ，有 $s = 1, c = \frac{1}{2}$ 。

5. Kernel Methods

推导 kernel LDA

(本题选做，自行作答，不用提交，答案参考南瓜书对应章节)